

Qwen3.5 合成受访者能否保留态度矛盾？

基于 CGSS 2012—2021 性别态度数据的人口效度审计

摘要

大语言模型越来越多地被用于模拟调查受访者，但生成一组听起来合理的个体回答，并不等于重建真实人口。本文以中国综合社会调查 2012、2018 和 2021 年五道性别态度题为基准，提出一套按目标统计量区分边际分布、异质性、关系结构和预测表现的人口效度审计，即分别检验合成人口能否恢复总体比例、人群分歧和题项关系。研究从三轮调查中抽取 300 名真实受访者，为每个 profile 重复生成五次，并将本地 Qwen3.5-9B 在当前 prompt 条件下的输出与同规模人类重抽样、监督机器学习模型和保留完整人类回答向量的联合 donor 基线比较。结果显示，Qwen3.5-9B 并非简单地整体偏传统：它在前四道公共机会相关题上明显给出更平等的回答，却低估夫妻均分家务的支持度；同时，它将真实样本中相对独立的家务题纳入更强的题项相关结构。五次重复生成增加了总方差，却主要表现为同一 profile 内部的随机波动，而非有效恢复 profile 之间的人群差异。有限人口信息确实限制个体态度预测，但不足以自动解释模型产生的总体分布和关系结构失真。

关键词：合成受访者；大语言模型；机器学习；公共意见；性别态度；中国

Abstract

Large language models can generate plausible survey answers without reproducing the population those answers are meant to represent. This article develops an estimand-indexed population-fidelity audit that separates marginal calibration, response heterogeneity, relational structure, and predictive benchmarking. The audit is applied to five repeated Qwen3.5-9B responses for each of 300 profiles sampled from the 2012, 2018, and 2021 Chinese General Social Survey. Under the present prompt and model setting, Qwen3.5-9B overstates egalitarianism on the first four items, understates support for equal housework, and over-associates the housework item with the rest of the battery. Sparse profile information is a real prediction limit, but it is not by itself a sufficient explanation for population-level distortion.

Keywords: synthetic respondents; large language models; survey simulation; population fidelity; machine learning; gender attitudes

1 引言

大语言模型进入社会科学研究以后，一个很有吸引力的设想是：既然模型能够理解身份描述、社会场景和问卷题目，它是否也能模拟调查受访者，从而为问卷预测、实验预调查、缺失值填补乃至低成本社会调查提供新的工具？这一设想之所以有吸引力，是因为传统调查正面临成本上升、拒访增加和样本覆盖不足等问题，而 LLM 可以在极短时间内根据给定人口特征生成大量回答。由此，合成受访者似乎提供了一种介于真实调查和统计模拟之间的新型数据来源。

问题在于，社会调查的目标并不是得到一组“听起来像某类人”的回答。如果要求一个语言模型扮演“45 岁、居住在城市、接受过大学教育的中国女性”，它很容易生成一组连贯的性别态度。但调查推断真正关心的是：大量类似模拟能否恢复真实人口中的均值、分歧、题项相关、群体差异和不确定性。换言之，本文所说的合成受访者，是 LLM 根据给定人口 profile 生成问卷答案的模拟对象；它首先应当被当作人口生成器来评估，而不只是被当作流畅的角色扮演者。^[1]

这一区分构成了 synthetic respondents 研究的核心争议。已有研究一方面提出“algorithmic fidelity”，认为人口特征条件化可以让模型逼近不同社会群体的意见；另一方面也发现，LLM 可能压缩方差、改变回归系数、对 prompt 措辞敏感，并且无法准确代表部分人口群体。现有争论仍留下一个重要的替代解释：如果人口学 profile 本身就不足以预测个人态度，那么 LLM 表现不佳是否只是信息不足，而不是生成模型产生了额外偏差？如果不建立一个同样只使用人口 profile 的参照基准，就很难判断 LLM 究竟是“没有足够信息”，还是在有限信息之外又制造了新的分布失真。

中国性别态度为这个问题提供了较严格的检验。性别平等并不是一条所有观点同步移动的单一轴线。一个人可能反对“男性能力天生强于女性”，也支持女性就业，却对夫妻是否应当均分家务持不同态度。关于“不均衡的性别革命”和“多种平等主义”的研究都强调，公共机会与家庭责任可以具有不同的变化速度和社会基础。如果 LLM 把人口 profile 压缩成“传统型”或“现代型”，它可能生成高度一致的回答，却抹去真实社会中具有意义的矛盾和领域分化。

本文提出三个问题：第一，零样本 LLM 能否恢复 CGSS 性别态度的边际分布？第二，它能否恢复人群异质性以及家务平等题与其他题项的弱联系？第三，模型误差主要来自 profile 信息不足，还是超出了相同信息条件下监督学习模型的预测边界？

相较于已有 synthetic respondents 研究，本文的增量不在于证明某个模型“更好”或“更差”，而在于把评估对象从单个回答的相似性推进到人口统计量的可用性：同

[1] ARGYLE L P, BUSBY E C, FULDA N, et al. Out of one, many: using language models to simulate human samples[J]. *Political Analysis*, 2023, 31(3): 337-351; AHER G V, ARRIAGA R I, KALAI A T. Using large language models to simulate multiple humans and replicate human subject studies[C]//*Proceedings of the 40th International Conference on Machine Learning*. PMLR, 2023: 337-371; SANTURKAR S, DURMUS E, LADHAK F, et al. Whose opinions do language models reflect?[C]//*Proceedings of the 40th International Conference on Machine Learning*. PMLR, 2023: 29971-30004; BISBEE J, CLINTON J D, DORFF C, et al. Synthetic replacements for human survey data? The perils of large language models[J]. *Political Analysis*, 2024, 32(4): 401-416; QU Y, WANG J. Performance and biases of large language models in public opinion simulation[J]. *Humanities and Social Sciences Communications*, 2024, 11: 1095.

一个合成人口必须同时经受均值、方差、相关结构和预测基准的检验。这个设计也把两个容易混淆的问题分开：人口学信息本来就难以精确预测个人态度，但这并不意味着模型可以系统性地扭曲总体分布。

由此，本文的主定位是计算社会科学方法审计，而不是一篇完整的中国性别态度解释论文。性别态度题组在本文中承担“结构性测试场景”的功能：它们既有清楚的调查基准，又包含公共机会、成就评价与家庭责任之间的潜在张力，能够检验模型是否会把真实人口中的矛盾压缩成过度一致的合成类型。本文的贡献主要体现在三个方面：第一，提出面向不同估计目标的人口效度审计框架；第二，展示 LLM 可能在均值、方差和关系结构上同时失真；第三，用监督机器学习和联合 donor 基线区分“profile 信息有限”与“生成器额外失真”。

2 文献综述

2.1 从计算社会科学到 LLM 合成受访者

计算社会科学的基本承诺，是利用数字数据、计算模型和可复现流程扩展社会科学对复杂社会过程的观察能力。早期计算社会科学更多依赖社交媒体、网络日志、文本语料和大规模行政数据；这些数据的优势在于规模，局限则在于并非为社会科学概念测量而设计。Lazer 等提出的计算社会科学议程强调，新的数字数据和计算方法必须服务于可解释的社会科学问题；Salganik 则进一步指出，数字时代研究的关键不只是数据规模，而是测量、抽样和推断规则是否透明。^[2]近年来，LLM 把计算社会科学的对象从“分析既有数字痕迹”推进到“生成可用于研究的数据对象”：模型可以进行文本标注、情绪判断、立场分类，也可以根据人口 profile 模拟问卷回答。国内关于大语言模型与社会科学的讨论，已经开始把它视为一种可能改变研究范式的工具，但同时也强调其带来的信息污染、权力分配、伦理治理和意识形态风险。

合成受访者研究正是在这一背景下兴起。Argyle 等提出，语言模型在给定人口特征后，可能生成与真实群体相似的回答分布，并把这种能力概括为 algorithmic fidelity。Aher 等进一步展示，LLM 在若干经典人类行为实验中可以复现实验结果。与此相对，Santurkar 等、Bisbee 等和 Qu 与 Wang 等研究指出，LLM 并不稳定地代表真实公众意见：模型输出会受到训练语料、prompt 设计、模型版本和群体刻板印象影响。国内相关讨论也开始把生成式大语言模型理解为“测试社会学”、大型社会模拟器和计算社会科学基础设施的一部分，并强调其对社会科学知识生产方式的影响。^[3]上述争论说明，合成受访者不能仅凭少量例子或单个准确率指标判断有效性，而应当明确比较对象、目标统计量和适用场景。

本文承接这一争论，但把评价重心从“模型像不像人”转为“模型能否恢复人口结构”。如果下游任务只是预测某个具体个体，个体误差是核心指标；如果下游任

^[2] LAZER D, PENTLAND A, ADAMIC L, et al. Computational social science[J]. Science, 2009, 323(5915): 721-723; SALGANIK M J. Bit by bit: social research in the digital age[M]. Princeton: Princeton University Press, 2018.

^[3] 龚为纲. 大语言模型助力计算社会科学迭代 [N]. 中国社会科学报, 2024-03-08; 梁玉成. 基于生成式大语言模型的“测试社会学”[J]. 探索与争鸣, 2024(11): 17-21; 吕鹏. 大型社会模拟器：社会知识生产的大科学装置 [J]. 探索与争鸣, 2024(11): 13-16.

务是估计总体均值，边际分布更关键；如果下游任务涉及量表、回归或群体差异，方差和协方差结构就不可或缺。国内计算社会科学论文通常强调“问题—数据—方法—解释”的连续性，本文也因此不把 LLM 评估处理成纯技术 benchmark，而是把模型误差放回社会调查和态度测量的语境中讨论。

这一转向也与调查方法文献中的测量效度问题相连。调查数据并不是受访者心理状态的直接记录，而是题干、选项、访问情境、受访者理解和抽样设计共同作用的结果。Groves 等和 Tourangeau 等关于调查误差和回答心理过程的讨论说明，问卷答案的有效性首先取决于题项是否被稳定理解，以及样本能否支持相应总体推断。^[4]如果 LLM 生成的是“看起来合理”的回答，却不能恢复真实样本中的边际比例、方差和题项关系，那么它在社会调查意义上仍然不能被视为有效合成受访者。

2.2 机器学习基准与社会调查推断

机器学习在社会科学中的主要价值，并不只是提高预测精度，而是提供一种透明的反事实基准。对于本文而言，监督机器学习模型回答的是一个窄问题：在预测阶段只给定相同人口 profile 时，调查数据训练出的模型最多能够恢复多少人口结构？如果这些模型也无法恢复总体分布，那么 LLM 的失败可以较大程度归因于 profile 信息不足；如果这些模型能够恢复边际和方差，而 LLM 不能，则说明 LLM 的生成机制产生了额外失真。

这一区分很重要，因为社会态度本来就难以由少数人口变量精确预测。年龄、性别、教育、城乡和婚姻状态只提供有限信息，不可能决定一个人的全部规范判断。因此，本文不把 HGB 或多项 logit 作为“公平竞赛”的对手，而是把它们作为结果知情的参照系。它们训练时看过调查答案，Qwen 没有；但在预测阶段，它们和 Qwen 面对的是同一批 profile。这样可以把“个人预测难”与“总体分布扭曲”分开。

2.3 性别态度的多维结构

性别态度之所以适合作为 LLM 人口效度的检验场景，是因为它天然包含矛盾、分化和情境依赖。既有研究表明，性别平等观念并不会在公共领域和家庭领域同步推进。England 提出“停滞的性别革命”，强调女性进入公共领域的规范变化快于家庭责任再分配；Knight 与 Brinton 则指出，所谓平等主义并非单一类型，而存在多种组合。这些研究共同提示，教育、代际、城乡和市场化过程可能塑造不同层面的性别观念，但公共参与、就业机会和家务分工之间并不必然形成一致结构。

对 LLM 而言，这种多维性构成了更严格的测试。如果模型只是根据 profile 调用“传统/现代”这一单轴类型，它可以生成很连贯的回答，却不能恢复真实受访者中的不一致。社会科学关心的恰恰是这些不一致：支持女性就业但不支持家务均分，或者赞成家务均分却在就业竞争上保留传统观念，都可能具有明确的制度和文化含义。因此，本文把 CGSS 五道性别态度题作为审计对象，不是因为它们构成完美量表，而是因为它们能检验模型是否会把真实社会中的领域分化压缩成过

^[4] GROVES R M, FOWLER F J, COUPER M P, et al. Survey methodology[M]. 2nd ed. Hoboken: Wiley, 2009; TOURANGEAU R, RIPS L J, RASINSKI K. The psychology of survey response[M]. Cambridge: Cambridge University Press, 2000.

度一致的合成态度。

3 分析框架与研究预期


设受访者 i 的人口 profile 为 X_i ，其在题项 j 上的真实回答为 $Y_{ij} \in \{1, \dots, 5\}$ ，LLM 输出为：

$$\tilde{Y}_{ij}^L = g_\theta(X_i, q_j, s), \quad (1)$$

其中 q_j 表示题目和 prompt 语境， s 表示随机 seed， θ 表示固定的预训练模型。一个输出在语言上合理，并不意味着它来自真实的条件分布：

$$P(Y_{ij} = k | X_i), \quad k = 1, \dots, 5. \quad (2)$$

因此，synthetic respondent 至少存在四个不同层次的效度：个体效度，即是否接近对应真实受访者的回答；边际效度，即五个选项的总体比例是否正确；异质性效度，即是否保留真实人群的方差；关系效度，即题项相关和人口学梯度是否接近调查数据。这些效度不必同步。模型可能猜不中具体个人，却仍能生成校准良好的总体；也可能均值接近，却把所有人都预测得过于相似。



部署门槛：每个必要层次都应落在人类同规模抽样参考区间内

图 3.1 合成调查受访者的人口效度审计框架

性别态度尤其适合检验关系效度。公共就业、能力判断和家庭内部责任分别涉及制度规则、抽象价值、亲密关系和实际成本。人类在这些领域之间出现不一致，并不必然是随机测量误差。相反，这种矛盾可能来自不同场景激活了不同判断标准。LLM 则可能根据年龄、教育和城乡等特征调用简化的社会类型，并在同一次回答五题时维持内部一致。本文将这种可能性称为“合成一致性”：模型生成的态度组合比真实人群更加单一和连贯。

当前设计能够识别合成一致性，却不能确定其具体来源。它可能来自预训练语料中的人口刻板印象，也可能来自同一 context 中的答案一致性压力。要识别机制，还需要比较“五题联合回答”与“五题分别在独立 context 中回答”。

4 数据与人类基准

4.1 CGSS 样本

研究使用 CGSS 2012、2018 和 2021 三轮独立横截面数据。分析样本要求 A425 有效、A421—A424 至少三题有效，同时人口 profile 变量和个人权重完整。最终样本分别为 11,668、12,478 和 7,710 人，合计 31,856 人。LLM 审计样本在每轮中抽取 100 个 profile，三轮合计 300 个 profile；抽样按性别、教育组和城乡居住分层，并在层内依据调查权重抽取。

表 4.1 人类基准样本与 LLM 审计样本规模

年份	CGSS 分析样本	LLM 审计 profile	LLM 重复次数
2012	11,668	100	5
2018	12,478	100	5
2021	7,710	100	5
合计	31,856	300	1,500 个 profile-repeat

五道题分别询问受访者是否同意：A421，男人以事业为重，女人以家庭为重；A422，男性能力天生比女性强；A423，干得好不如嫁得好；A424，经济不景气时应该先解雇女性员工；A425，夫妻应该均等分摊家务。根据 CGSS 问卷示卡和本文 prompt 设置，五题同意度选项均按 1“完全不同意”至 5“完全同意”记录。由于 A421—A424 是传统方向陈述，分析时使用 6 - Y 反向计分；A425 本身是平等方向陈述，保持原值。所有结果均统一为 1 至 5 分，数值越高越平等。

表 4.2 性别态度题项的原始编码、统一编码与 prompt 编码

题项	题干方向	CGSS 原始/LLM prompt 选项	本文统一编码
A421	传统方向：男主外、女主内	1= 完全不同意，5= 完全同意	6 - Y
A422	传统方向：男性能力更强	1= 完全不同意，5= 完全同意	6 - Y
A423	传统方向：婚姻高于个人成就	1= 完全不同意，5= 完全同意	6 - Y
A424	传统方向：经济不景气时优先解雇女性	1= 完全不同意，5= 完全同意	6 - Y
A425	平等方向：夫妻均分家务	1= 完全不同意，5= 完全同意	Y

A425 只有一道正向措辞题，不能被视为完整的家庭分工潜变量。它与前四题的低相关可能同时包含内容领域、正反措辞、同意偏差和单题误差。本文将这种低相关视为需要 synthetic respondents 复现的人类经验结构，而不是宣称五题已经严格识别出两个潜变量。

4.2 人类态度结构

完整加权样本显示，A421—A424 之间存在稳定的共同变化，而 A425 与前四题联系很弱。A425 与前四题的平均绝对加权 Pearson 相关在 2012、2018 和 2021 年分别为 0.049、0.078 和 0.078；未加权 Pearson 和 polychoric 估计也仅为 0.051—

0.091。与此同时，题项均值差异明显：反对就业歧视和支持家务均分的比例较高，而家庭角色题更加传统。

因此，一个有效的合成人口不能简单地把所有人放在同一条“传统—现代”轴线上。它需要同时恢复不同题目的难度和有限的领域相关性。

5 计算审计设计

5.1 Profile 抽样与 LLM 生成

每轮抽取 100 名受访者，共 300 人。样本按性别、教育组和城乡居住分层，各层配额依据加权人口规模确定，层内按 CGSS 权重进行概率比例抽样。输入 LLM 的资料包括调查年份、省份、性别、年龄、教育、户口、城乡居住、婚姻和相对家庭经济状况，不包含任何真实态度答案。

主模型为本地运行的 Qwen3.5-9B MLX 4bit，通过 LM Studio 本地 OpenAI 兼容服务在 24GB 统一内存的 Apple M4 设备上执行。temperature 设为 0.7，top-p 为 0.9；LM Studio 当前接口未在本轮调用中暴露可复现 seed 字段，因此重复生成被视为同一解码设置下的随机重复。

主要 prompt 要求模型以该受访者身份回答五道题，明确说明题目独立、没有正确答案，提供中文文字标签与数字的一一对应，并强制输出 JSON 整数。程序检查五个键是否完整、分数是否在 1—5 之间。主要分析使用 neutral_verbal 条件，每个 profile 以不同 seed 重复生成五次，五次离散结果构成经验预测分布。第一次生成保留为敏感性分析。完整 prompt 模板、profile 文本模板和复现命令保存在配套材料中；在本地运行记录中，共发起 1,500 次调用，全部成功，成功率为 100%。

需要说明的是，当前 Qwen3.5 复测尚未包含独立题项呈现实验。因此，本文关于题项相关结构的结论限于“联合呈现的五题回答是否恢复人类相关矩阵”，不能进一步识别这种相关放大究竟来自共同上下文、模型内部表征，还是二者共同作用。

5.2 机器学习基准

为了区分“profile 信息不足”和“LLM 额外失真”，研究加入三类使用真实调查训练的参考模型：调查加权边际 prior、多项 logit 和 Histogram Gradient Boosting (HGB)。三个模型在预测时获得与 LLM 完全相同的人口信息。数值变量进行中位数填补和标准化，省份使用 one-hot 编码，训练权重标准化为均值 1。

关系结构另设一个简单的联合 donor 基线。它在同一年度、性别、教育组和城乡居住组合内，按照调查权重抽取真实受访者的完整五题回答向量。该方法使用了结果信息，不能与 zero-shot LLM 视为等训练预算；它的作用是检验：只要保留回答的联合结构，稀疏人口 profile 是否仍必然导致相关结构失真。

主要评估采用五折 out-of-fold prediction。每个真实受访者的答案都由未使用其答案训练的模型预测。随后使用 wave 和 row_id 精确匹配 LLM 的 300 个 profile。因此，Qwen、logit 和 HGB 面对的是同一批真实受访者。

这不是训练信息完全公平的竞赛。HGB、logit 和边际 prior 使用 CGSS 标签训

练, Qwen 则是 zero-shot。因此, 监督模型优于 Qwen 本身不是本文的核心论点。该比较控制的是预测时 profile 信息, 而不是训练预算; 它回答的窄问题是: 人口 profile 信息有限, 是否足以解释 Qwen 的全部误差? [5]

5.3 指标

如果模型 m 对五个选项给出的概率是 $p_{mij}(k)$, 其期望得分为:

$$\hat{\mu}_{mij} = \sum_{k=1}^5 k p_{mij}(k). \quad (3)$$

需要说明的是, 不同模型的 $p_{mij}(k)$ 来源不同。对多项 logit 和 HGB 而言, 它是模型输出的预测概率; 对加权边际 prior 而言, 它是训练样本中的选项频率; 对 Qwen 而言, 它是同一 profile 五次重复生成得到的经验频率。因此, 本文比较的是不同方法对同一目标分布的重建表现, 而不是它们内部概率估计机制的完全对称性。个体误差使用有序平均绝对误差:

$$\text{OMAE}_m = \frac{1}{NJ} \sum_{i=1}^N \sum_{j=1}^J |\hat{\mu}_{mij} - Y_{ij}|. \quad (4)$$

总体分布使用 total variation:

$$\text{TV}_{mj} = \frac{1}{2} \sum_{k=1}^5 |\hat{\pi}_{mjk} - \pi_{Hjk}|. \quad (5)$$

同时报告均值误差、Ranked Probability Score 和方差比:

$$R_{mj}^V = \frac{\text{Var}_m(Y_j)}{\text{Var}_H(Y_j)}. \quad (6)$$

方差比低于 1 表示 synthetic sample 压缩了人群差异。对 Qwen 而言, 主分析把五次重复生成合并为 profile 层面的经验预测分布, 并另以第一次生成为敏感性分析; 这会比单次生成保留更多随机波动, 但仍不足以保证恢复人类方差。题项结构则通过相关矩阵 RMSE 以及 A425 与前四题的平均绝对相关衡量。HGB 与 Qwen 的误差差异采用 profile-cluster bootstrap。程序先在同一 profile 内部对五题误差差取均值, 再在每轮调查内部重抽 profile, 重复 2,000 次。

为避免用任意阈值判定“接近人类”, 每轮另按原有分层、配额和权重重复抽取 100 名真实受访者 1,000 次, 构造各指标的中央 95% 人类抽样参考区间。该区间描述同规模人类样本的正常波动, 不是对 CGSS 有限总体参数的置信区间。只有当模型结果落在目标指标的参考区间内, 才视为通过该项人口效度检验。

[5] MULLAINATHAN S, SPIESS J. Machine learning: an applied econometric approach[J]. Journal of Economic Perspectives, 2017, 31(2): 87-106; QWEN TEAM. Qwen3 technical report[EB/OL]. arXiv:2505.09388, 2025.



6 结果

6.1 Qwen 的偏差具有明确题项结构

将三轮均值等权平均后，Qwen3.5 并不是在所有题上沿同一方向偏离。它在 A421—A424 上系统性高估平等态度，尤其在家庭角色、男性能力和婚姻成就三题上更明显；但在 A425 上反而低估夫妻均分家务的支持度。这说明新模型的主要问题不是简单的“保守偏差”，而是把公共机会和平等规范推向更整齐的现代化叙事，同时没有同等恢复家务平等这一私域题项。

表 6.1 三轮平均后的题项均值比较

题项	CGSS 加权均值	Qwen 均值	误差
A421 家庭角色	2.723	3.842	+1.119
A422 男性能力	3.107	4.250	+1.143
A423 婚姻高于成就	2.920	3.630	+0.710
A424 优先解雇女性	3.896	4.076	+0.180
A425 夫妻均分家务	3.983	3.577	-0.406



注：所有题项均已统一为数值越高代表越平等。A421家庭角色，A422男性能力，A423婚姻成就，A424就业保护，A425家务均分。

图 6.1 Qwen3.5-9B 的边际分布偏差

上图显示，模型误差集中出现在题项层面，而不是均匀地偏离人类样本。A421—A423 的均值被明显推高，A424 相对接近人类样本，A425 则出现相反方向的低估。这种“公共题更平等、家务题更保守”的组合，正是后文关系结构失真的基础。


6.2 模型压缩了分歧，也制造了过度一致

neutral prompt 条件下，15 个“年度 × 题项”单元的总方差比中位数为 0.801，平均为 0.794。这个数字看似比旧版单次生成更接近人类方差，但方差分解显示，Qwen3.5 预测方差中平均 68.2% 来自同一 profile 五次重复生成之间的随机波动；真正反映 profile 之间差异的方差比平均只有 0.265。换言之，模型并非有效恢复了人群异质性，而是用解码随机性补上了一部分总体离散程度。

更重要的是，模型仍然改变了五题之间的关系。真实受访者对家务均分的态度几乎独立于前四题，而 Qwen3.5 把它们组织成更强的一致性组合。这个相关放大不是极端失真，但依然具有实质意义。

表 6.2 A425 与前四题的平均绝对相关

年份	CGSS	Qwen	相关矩阵 RMSE
2012	0.051	0.249	0.185
2018	0.067	0.335	0.184
2021	0.061	0.225	0.121



注：A425为家务均分题。profile间方差低说明模型更依赖同一社会类型模板，而不是有效区分受访者。

图 6.2 Qwen3.5-9B 的异质性与关系结构偏差

同规模人类样本的参考区间进一步表明，这些偏差不是抽到 100 人后常见的随机波动。把三轮调查各自的中央 95% 区间取保守并集后，人类样本的绝对题项均值误差为 [0.036, 0.168]，Qwen3.5 为 [0.622, 0.801]；TV 为 [0.046, 0.104]，Qwen3.5 为 [0.256, 0.300]。这两类边际指标三轮均明显超出人类参考区间。方差比的人类区间为 [0.846, 1.141]，Qwen3.5 在 2012 年为 0.906，2018 和 2021 年分别为 0.737 和 0.739；相关矩阵 RMSE 的人类区间为 [0.047, 0.141]，Qwen3.5 在 2012 和 2018

年为 0.185 和 0.184，2021 年为 0.121。因此，新模型不是在所有指标上同等失败，而是在边际校准上稳定越界，在异质性和关系结构上呈现年度差异。




图 6.3 Qwen3.5-9B 与同规模人类抽样参考区间

上图把这个判断可视化为一个“部署门槛”：灰色区间表示 100 名人类受访者在重复抽样下的正常波动，橙色三角表示 Qwen3.5-9B。边际均值和选项分布明显远离人类抽样可解释的范围；结构指标的偏离相对温和，但仍提示模型没有完全恢复人类态度关系。

6.3 相同人口信息下，ML 明显优于 Qwen

在完全相同的 300 个 profile 上，HGB 和 logit 的个体 MAE 仍接近 1 分，说明人口学 profile 确实不足以精确预测个人态度。这与性别态度研究中人口学模型解释率有限的事实一致。但这些模型能够较好恢复总体分布，而 Qwen3.5 仍明显落后于调查训练基准。

表 6.3 相同 300 个 profile 上的模型比较

模型	Ordinal MAE	绝对均值误差	TV	方差比
加权边际 prior	0.975	0.127	0.097	0.992
Multinomial logit	0.935	0.112	0.081	0.982
HGB	0.923	0.095	0.071	0.987
分层联合 donor	0.987	—	0.070	0.973
Qwen3.5-9B	1.175	0.712	0.281	0.794

边际 prior 尤其具有解释意义。它不学习人口特征与态度之间的映射，只复制训练样本的选项频率，却仍显著优于 Qwen。不过，这不是无监督或无标签基线：它仍然使用了训练样本的真实 Y 分布。它的作用是区分个体化预测和 base-rate calibration，而不是建立完全相同的训练条件。

联合 donor 基线补上了逐题分类器无法检验的关系结构。它的相关矩阵 RMSE 为 0.085，A425 与前四题平均绝对相关为 0.105；Qwen3.5 分别为 0.163 和 0.270。逐题学习器能够恢复边际分布，但本身并不定义完整的联合回答生成器；Qwen 能够生成联合回答，却仍把题项联系得过强；联合 donor 处在两者之间：它保留完整人类回答向量，而不额外制造超出人类样本的意识形态一致性。




图 6.4 机器学习与联合 donor 基准

配对 bootstrap 显示，Qwen3.5 五次生成的 profile 均值绝对误差平均比 HGB 高 0.254 分，95% 区间为 [0.207, 0.305]。差距最大的是 A421、A422 和 A425；A424 上二者差异较小。

6.4 跨时期外推

使用 2012 和 2018 训练、2021 测试后，历史边际 prior、logit 和 HGB 仍明显优于 Qwen。即使禁止参考模型接触 2021 标签，仅使用历史调查训练的模型仍明显优于 Qwen。这个结果不能消除训练信息不对称，却说明 Qwen 的误差并非只是因为参考模型看过目标年份数据。

表 6.4 跨时期外推：2012—2018 训练，2021 评估

模型	Ordinal MAE	TV	方差比
历史边际 prior	0.997	0.113	0.960
Multinomial logit	0.961	0.139	0.928
HGB	0.945	0.107	0.959
Qwen3.5-9B	1.145	0.288	0.739

7 讨论

7.1 方法论含义：从回答相似性到人口效度

本文最有力的结论不是“HGB 比 LLM 更准”。监督模型直接以 CGSS 答案为训练目标，其优势并不意外。更窄且可辩护的结论是：有限人口信息只能解释一部分个体预测误差，不足以解释 Qwen 额外产生的方向性偏差、profile 间差异压缩和错误相关结构。该设计不能把这种额外失真单独归因于模型架构，因为预训练、prompt 和缺少任务校准同样可能参与其中。

因此，synthetic respondents 的评价不能只问“是否猜中某个人”。对于社会科学而言，一个模型即使个体准确率有限，只要能够校准总体分布，仍可能具有描述用途。相反，如果它把人群变得更同质，并制造现实中不存在的态度一致性，就不能用来估计分布、构造量表或分析群体差异。

这个结论也提示，LLM 评估需要从通用 benchmark 转向任务化 benchmark。MMLU、推理题和人类偏好评分可以说明模型的一般能力，却不能说明它是否能作为某个具体社会调查的人口替代物。合成受访者的有效性必须相对于下游 estimand 来定义：估计均值、估计相关、估计回归系数和构造潜变量，对数据结构的要求不同。本文提出的人口效度审计，就是把这些要求拆开，而不是用一个综合准确率掩盖失败发生在哪一层。

7.2 实质含义：态度矛盾不是噪声

Qwen3.5 的结果不是简单的保守或自由偏差。它在前四题上普遍给出更平等的回答，却在家务均分题上低估支持度。用单一“political bias”标签描述这种模式会掩盖其领域选择性：模型似乎更容易生成一种抽象公共平等叙事，却没有相应恢复人类样本中关于家庭责任的分歧。

人类态度中的矛盾本身具有社会意义。一个人可以接受女性进入公共领域，却不愿相应改变家庭责任；也可能赞成家务平等，却对就业竞争持传统立场。如果 synthetic respondents 倾向于输出内部一致的“传统者”和“平等者”，它们会抹去社会科学真正需要解释的态度组合。

这对中国性别态度研究尤其重要。公共领域平等、就业保护和家庭内部责任并不处在同一制度场景中，受访者在不同题项上的判断可能受到国家话语、市场竞争、婚姻家庭利益和代际社会化的共同影响。A425 作为单题不能充分代表完整的家庭分工潜变量，但它与前四题的弱相关本身就是一个重要经验事实。LLM 如果把这种弱相关放大为强相关，等于把社会态度中的张力误写成一种更整齐的意

识形态结构。

7.3 限制

第一,当前只检验 Qwen3.5-9B。在完成跨模型比较之前,不能把结论写成“LLM 普遍如此”。第二,每个 profile 的五次生成足以估计粗略的经验预测分布,却不足以恢复完整的选项概率或精细计算 entropy 与 calibration。第三,本轮 Qwen3.5 复测只保留 neutral_verbal 主条件,没有同时完成独立题项呈现和完整 prompt 消融,因此无法识别相关放大来自共同上下文还是模型内部表征。第四,A425 是单题且与前四题题干方向不同。CGSS 能够拒绝五题严格单维假定,却不能完全分离领域效应与题项方法效应。第五,人类抽样参考区间把完整加权 CGSS 样本当作基准,只复现本研究采用的分层和权重,没有传播多阶段抽样中的全部 PSU 和分层不确定性。第六,无法核实 Qwen 预训练语料是否包含 CGSS 题目、相关讨论或相近规范表述。因此,当前输出偏差不能直接解释为训练语料频率或问卷记忆的证据。

这些限制并不削弱本文的核心判断,但限定了它的外推范围。更强的下一步设计应当包括三项内容:其一,比较不同模型家族和参数规模,判断失真是否具有模型普遍性;其二,提取完整候选选项概率,区分模型“自信地错误”和“犹豫但被迫输出一个答案”;其三,使用更丰富的性别态度题组或外部调查数据,进一步区分领域差异、措辞效应和单题测量误差。

8 结论

合成受访者应当被当作人口生成器,而不仅是流畅的角色扮演。本文发现,在当前 CGSS 性别态度任务和 prompt 设置下,本地部署的 Qwen3.5-9B 没有恢复人类样本的若干基本性质:它在公共机会题上高估平等态度,在家务均分题上低估支持度,用重复生成随机性补足一部分总体方差,却没有充分恢复 profile 之间的人群差异,并把真实社会中相对独立的家务平等态度纳入更一致的态度组合。

机器学习与人类抽样基准改变了对这一失败的解释。人口 profile 确实不足以精确预测个人态度,但相同预测信息经过调查数据校准后,可以更好地恢复总体分布;保留完整人类回答向量的简单 donor 也能恢复大部分关系结构。Qwen3.5 的边际指标稳定超出同规模人类样本的正常波动,结构指标则显示出较弱但仍存在的相关放大。因此,其失真不能完全归结为 profile 信息不足。不过,本文也没有证明所有 LLM 都存在同样问题,更没有识别训练语料或模型架构中的单一机制。

当前证据支持一个更有限、也更重要的方法论结论:任何关于 synthetic population 的主张,都需要同时检验 base rate、异质性和协方差结构,并明确区分模型在训练阶段与预测阶段分别看到了什么信息。对于计算社会科学而言,LLM 的价值不应建立在“替代真实受访者”的笼统想象上,而应建立在可审计、可复现、与具体研究问题相匹配的使用边界上。换言之,LLM 可以成为社会调查研究的辅助工具,但只有在经过面向具体 estimand 的审计之后,才可能进入严肃的经验推断流程。

参考文献

- [1] ARGYLE L P, BUSBY E C, FULDA N, et al. Out of one, many: using language models to simulate human samples[J]. *Political Analysis*, 2023, 31(3): 337-351.
- [2] AHER G V, ARRIAGA R I, KALAI A T. Using large language models to simulate multiple humans and replicate human subject studies[C]//*Proceedings of the 40th International Conference on Machine Learning*. PMLR, 2023: 337-371.
- [3] SANTURKAR S, DURMUS E, LADHAK F, et al. Whose opinions do language models reflect?[C]//*Proceedings of the 40th International Conference on Machine Learning*. PMLR, 2023: 29971-30004.
- [4] BISBEE J, CLINTON J D, DORFF C, et al. Synthetic replacements for human survey data? The perils of large language models[J]. *Political Analysis*, 2024, 32(4): 401-416.
- [5] QU Y, WANG J. Performance and biases of large language models in public opinion simulation[J]. *Humanities and Social Sciences Communications*, 2024, 11: 1095.
- [6] 龚为纲. 大语言模型助力计算社会科学迭代 [N]. *中国社会科学报*, 2024-03-08.
- [7] 梁玉成. 基于生成式大语言模型的“测试社会学”[J]. *探索与争鸣*, 2024(11): 17-21.
- [8] 吕鹏. 大型社会模拟器：社会知识生产的大科学装置 [J]. *探索与争鸣*, 2024(11): 13-16.
- [9] LAZER D, PENTLAND A, ADAMIC L, et al. Computational social science[J]. *Science*, 2009, 323(5915): 721-723.
- [10] SALGANIK M J. Bit by bit: social research in the digital age[M]. Princeton: Princeton University Press, 2018.
- [11] GROVES R M, FOWLER F J, COUPER M P, et al. *Survey methodology*[M]. 2nd ed. Hoboken: Wiley, 2009.
- [12] TOURANGEAU R, RIPS L J, RASINSKI K. *The psychology of survey response*[M]. Cambridge: Cambridge University Press, 2000.
- [13] MULLAINATHAN S, SPIESS J. Machine learning: an applied econometric approach[J]. *Journal of Economic Perspectives*, 2017, 31(2): 87-106.
- [14] ENGLAND P. The gender revolution: uneven and stalled[J]. *Gender & Society*, 2010, 24(2): 149-166.
- [15] KNIGHT C R, BRINTON M C. One egalitarianism or several? Two decades of gender-role attitude change in Europe[J]. *American Journal of Sociology*, 2017, 122(5): 1485-1532.
- [16] BURNS N, GALLAGHER K. Public opinion on gender issues: the politics of equity and roles[J]. *Annual Review of Political Science*, 2010, 13: 425-443.
- [17] QWEN TEAM. Qwen3 technical report[EB/OL]. arXiv:2505.09388, 2025.
- [18] 中国人民大学中国调查与数据中心. 中国综合社会调查: 2012、2018、2021[DS]. 北京: 中国人民大学, 2021.