



武汉大学
WUHAN UNIVERSITY

Uneven Change in Gender-Equality Attitudes: A Re-examination Based on CGSS 2012–2021 and an LLM Synthetic Respondent Audit

性别平等观念的不均衡变化： 基于 CGSS 2012-2021 的再考察与 LLM 合成受访者审计

——第二届中国高校PPE论坛——

宋歌

武汉大学 弘毅学堂 政治学、经济学与哲学

汇报时间：2026 年 8 月

汇报路径



现实中的态度并不整齐；把它压成单一总分或合成“理想类型”，
都会损失有意义的社会结构。

研究问题

性别平等观念的不均衡变化



“支持性别平等”是一个单一维度吗？

反对“男性能力天生更强”的人，是否也一定赞成夫妻均等分担家务？

常见测量做法

- 将多道性别态度题合并为一个总分
- 默认各题反映同一潜在态度
- 比较谁更“传统”或更“现代”

本文的经验问题

- 社会机会评价与家庭责任规范是否共享同一结构？
- 教育、媒介和性别位置是否以相同方式关联两类态度？
- 若不相同，五题总分会遮蔽哪些社会差异？

数据入口：CGSS A421–A425；2012、2018、2021 三轮独立横截面。

理论预期：不均衡的性别革命

制度承认、资源获得与家庭责任的变化并不同步

社会机会与成就评价

教育扩张、劳动参与与公共制度较早承认女性进入学校和劳动力市场的正当性。教育与信息资源因此更可能关联事业、能力、婚姻依附和就业权利判断。

预期关联

教育、媒介、城市经验更强；性别差距存在但较小。

家庭责任规范

家务、照料与婚育责任仍嵌入亲密关系和日常分工。抽象的平等原则不必然改变家庭内部的责任伦理与利益位置。

预期关联

教育与媒介梯度较弱；女性与男性的位置差异更突出。

理论参照：England (2010); Knight & Brinton (2017); Scarborough et al. (2019); 中国语境讨论见原论文文献综述。

本文贡献不是再报告一次“男女有差异”

- ① 测量层面：检验五题严格单维假定，而非先验接受总分。
- ② 解释层面：直接比较同一变量在两个领域中的系数差异，而非用“一个显著、一个不显著”代替检验。
- ③ 时间层面：在三轮独立样本中检验关系结构能否重复，并谨慎处理 2021 年的变化线索。
- ④ 方法延伸：把 LLM 合成受访者作为人口生成器审计，检验其能否恢复边际分布、群体异质性和相关结构。

核心对象不是一个“平等程度”总分，而是不同领域的态度如何由不同社会位置组织起来。

研究设计

性别平等观念的不均衡变化

数据与测量：三轮独立横截面，五道共同题项

分析样本

2012: 11,668 人

2018: 12,478 人

2021: 7,710 人

合计: **31,856 人**

两个结果变量

社会机会态度: A421–A424 均值

家务均分规范: A425 单题

年度内标准化 ($M = 0, SD = 1$)

A421–A424 = 社会机会态度; A425 = 家务均分规范

题项	内容	方向	处理
A421	男人事业为重，女人家庭为重	传统	反向
A422	男性能力天生比女性强	传统	反向
A423	干得好不如嫁得好	传统	反向
A424	经济不景气先解雇女性	传统	反向
A425	夫妻应均等分摊家务	平等	保留

样本按题项、核心解释变量、控制变量与权重完整性筛选；三轮独立横截面，不是面板。

识别策略：从测量结构到系数差异



推断处理

CGSS 个人权重；省份层聚类；CR2 小样本修正；Satterthwaite 自由度。2021 年仅 21 个省份簇，避免依赖常规渐近标准误。

解释边界


估计量是条件关联。跨年比较只用于判断关系结构是否重复或出现变化线索，不识别年龄、时期、队列，也不作因果解释。

CGSS 结果

性别平等观念的不均衡变化

发现一：五题不满足严格单维假定

A425 在三轮中都几乎不参与 A421-A424 的共同变化



- A421-A424 载荷：0.41-0.73
- A425 EFA 载荷：**0.066 / 0.091 / 0.096**
- A425 ordinal CFA 载荷：0.081 / 0.127 / 0.120
- 与前四题均值相关：0.054 / 0.074 / 0.080
- 四题 α ：0.636 升至 0.725；加入 A425 后下降

能说什么

可拒绝五题严格单维假定；A421-A424 具有可重复共同结构。


不能说什么

A425 只有一题且措辞方向不同，不能据此宣称已验证两个完整潜变量。

发现二：同一社会位置在两个领域中的关联不同

同一社会位置在两个领域中的关联方向不同

系数差 = 家务均分规范 - 社会机会态度；蓝色表示社会机会更强，绿色表示家务均分更强；加粗为 95% CI 不跨 0



同一组解释变量更能拟合社会机会态度



左：堆叠模型中的系数差，负值表示社会机会态度关联更强，正值表示家务均分规范关联更强；右：分领域加权 OLS 的 R^2 。低 R^2 也可能来自 A425 单题误差与天花板效应。

如何解释领域差异：资源梯度与性别位置

教育与媒介：社会机会关联更强


教育每增加 6 年，社会机会态度高约 **0.25–0.35 SD**；家务均分规范仅高 **0.05–0.11 SD**。教育系数差三轮均显著为负。媒介方向一致，但 2021 年差异未达常规显著水平。

女性位置：家务规范差距更大

女性相对男性的社会机会态度差距为 **0.11–0.21 SD**；家务均分规范差距为 **0.22–0.34 SD**。系数差三轮均显著为正。

教育并非与家务平等无关；更准确的结论是，它主要区分社会机会判断，而性别位置更能区分家庭责任判断。

性别差距在家务均分规范上系统性更大



重复形状

三轮中，家务面板的男女均值哑铃始终更长；这不是单一年份的偶然结果。

伴侣状态扩展

社会机会态度的性别差距随伴侣状态变化；家务态度的相应交互三轮均不显著，差距更稳定。


实质含义

家务均分更接近处境与利益判断，而非教育资源自动转化的抽象价值。

2021 年：教育与 A425 的相对脱钩明显扩大

2021 年教育与 A425 的相对斜率明显左移

横轴为教育 $\times$ A425 相对斜率的跨年度系数差；负值表示教育更集中地关联社会机会题项



最稳妥的表述是“2021 年的相对斜率差异明显扩大”，而不是“教育持续失效”。

稳健性与行为效度：结果支持结构差异，但仍有限

支持核心判断的复核

- 逐题模型：教育与媒介对 A421–A424 多数为正，A425 较弱
- Ordinal CFA：更换相关结构与估计方法后，A425 载荷仍低
- 题项层有序模型：2021 年教育相对斜率差异仍显著

不能越过的证据边界

- A425 是单题，且正向措辞，领域与措辞效应不能完全分离
- 2012 年 A425 同实际家务时间均等程度相关仅 $r = 0.045$
- 态度赞同不能替代家庭行为与夫妻双方报告

CGSS 部分结论：总分平均掉了两种不同信号

社会机会共同结构
A421-A424
教育、媒介关联较强

家务均分规范
A425 单题
性别位置差距较大

五题总分
压低资源梯度
压低领域性别差异


态度矛盾不是测量噪声的同义词。它可能是公共制度、资源获得与家庭责任变化不同步的经验表现。

LLM 审计

性别平等观念的不均衡变化

为什么把 LLM 当作“镜像检验”？

如果领域矛盾只是随机噪声，合成受访者不必恢复它；如果它有结构意义，恢复失败就值得审计



部署门槛：每个必要层次都应落在人类同规模抽样参考区间内

生成设计

Qwen3.5-9B；每轮抽取 100 个真实人口 profile；输入年份、省份、性别、年龄、教育、户口、城乡、婚姻和家庭经济；不输入真实态度答案。

重复与对照

300 profiles × 5 次生成 = 1,500 份；对照同规模人类重抽样、监督 HGB/多项 logit 和联合 donor。

审计对象不是“回答听起来像不像人”

1 边际分布

均值、方差、选项概率和 TV 距离是否接近真实人口？

2 群体异质性

性别、教育、城乡等群体差异是否方向与幅度都合理？

3 关系结构



题项相关、领域独立性和态度矛盾是否被保留？

4 预测基准

与使用相同 profile 信息的传统基线相比，是否额外改善？

人口效度要求同时通过边际、异质性与协方差结构；单个均值接近远远不够。

Qwen3.5 的偏差不是“整体更保守”或“整体更平等”



左：三轮平均题项均值偏差；右：A425 同 A421-A424 平均绝对相关。Qwen 结果均稳定超出同规模人类重抽样的参考区间。



结构性失真：LLM 制造了过度一致的“现代类型”

边际方向相反

A421–A424 被高估 **+0.18** 至 **+1.14** 分；A425 却被低估 **-0.41** 分。偏差具有明确领域方向，不能用单一“模型更进步/更保守”概括。

相关结构被压缩


真实 CGSS 中 A425 同前四题平均绝对相关仅 **0.05–0.07**；Qwen 提高到 **0.23–0.34**，约为真实值的 **3.7–5.0** 倍。

模型不是简单遗漏了“噪声”，而是把真实人口中的领域张力改写成更整齐的一致性结构。

为什么不能把失败全部归因于 profile 信息不足?

同样只使用人口 profile, Qwen3.5 的边际分布失真最大

颜色按各指标内的误差标准化, 越深越差; 方差比按 $|1 - \text{方差比}|$ 着色



监督 HGB 与 donor 使用真实态度训练, 不能作为生成替代方案; 它们在这里是诊断基线, 用于判断同样人口信息下可恢复的边际结构。

LLM 结论的适用范围

本文能够支持

- Qwen3.5-9B 在当前 zero-shot 设计下人口效度较差
- 失真同时发生于边际分布和相关结构
- 模型倾向生成内部更一致的态度组合

本文不能推出

- “所有 LLM 都不能合成调查受访者”
- prompt 改写、概率校准或微调一定无效
- 监督基线可以替代真实调查

更准确的结论是：在把 LLM 用于人口推断前，必须逐层审计，而不能由个案回答的流畅度推断总体有效性。

结论

性别平等观念的不均衡变化

两篇研究合在一起，得到同一个方法论判断

真实人口

性别平等态度按领域分化；教育资源与性别位置组织出不同关联结构。

常规指数

五题总分把领域分化平均掉，使资源梯度和性别位置差异同时变弱。

合成人口

LLM 进一步把张力压缩成一致类型，偏离边际分布并夸大题项相关。

无论是构造量表还是生成合成受访者，都不能把“内部一致”自动当作“更接近现实”。



与 PPE 论坛主题的连接：发展、平等与真实自由

Politics

公共制度承认女性进入教育与就业，并不自动把平等原则带入家庭。公共正义与私人责任之间仍有制度边界。

Economics

教育和信息资源更强地对应社会机会判断；家庭分工还受时间约束、议价位置与照料制度影响。

Philosophy

形式上的平等赞同不等于可行能力与真实自由。测量和 AI 若抹去矛盾，也会误判人的实际处境。

论坛关联的核心不是附会“AI”或“性别”，而是：发展如何从制度权利转化为家庭日常中的实质自由。

研究局限

这些限制影响外推边界，不推翻核心诊断

局限来源		对结论的约束
测量	A425 仅一道正向题 领域与措辞效应不能完全分离	不宣称验证两个完整潜变量。
设计	三轮独立横截面 不能识别因果、年龄/时期/队列	跨年结果只作关系结构比较。
行为	A425 是规范赞同 同实际家务时间关系很弱	不把态度变化等同于行为变化。
LLM	单一模型、单一 prompt profile 字段仍然有限	不外推到所有模型和生成设置。
基线	监督模型使用真实态度训练 用于判断可恢复的边际结构	只作诊断，不是调查替代方案。

局限收窄外推范围，但不改变两项核心事实：五题严格单维假定不成立；当前 LLM 没有恢复真实人口的领域结构。

下一步：把“领域”与“措辞”真正拆开

调查测量

- 家务、育儿、老人照料、家庭决策多题测量
- 每个领域平衡正反措辞
- 结合时间日记与夫妻双方报告
- 用面板或制度变化识别态度与行为关系

合成人口审计

- 跨模型、跨 prompt、跨呈现方式复现
- 比较独立题项与联合问卷生成
- 获取完整选项概率并进行人口校准
- 将协方差结构列为最低审计要求



武汉大学
WUHAN UNIVERSITY

**Development is the process of expanding
the real freedoms that people enjoy.**

感谢聆听，欢迎各位老师批评指正！

——第二届中国高校PPE论坛——

宋歌

武汉大学 弘毅学堂 政治学、经济学与哲学

汇报时间：2026 年 8 月